

LAPORAN UTS KECERDASAN BUATAN

DETEKSI UJARAN KEBENCIAN

Disusun Oleh:

Robby Firmansyah

312210643

TI.22.A.SE.1

Link Github : <https://github.com/IDOYGAMING/UTS-KECERDASAN-BUATAN-SEMESTER-7.git>

1. Latar Belakang

Perkembangan media sosial seperti Twitter memberikan ruang interaksi publik yang sangat luas. Namun, kebebasan berekspresi tersebut tidak jarang disalahgunakan untuk menyebarkan ujaran kebencian. Ujaran kebencian dapat memicu konflik sosial, diskriminasi, dan dampak psikologis pada individu maupun kelompok tertentu. Oleh karena itu, diperlukan sistem otomatis untuk mendeteksi ujaran kebencian agar dapat membantu proses moderasi konten dan menciptakan lingkungan digital yang lebih sehat.

2. Metodologi

2.1 Dataset

Dataset yang digunakan berasal dari kumpulan tweet berbahasa Inggris yang telah diklasifikasikan menjadi tiga kelas: hate speech (0), offensive language (1), dan neither (2). Untuk keperluan penelitian ini, label diubah menjadi biner, yaitu: kelas 0 dan 1 digabung menjadi label 1 (mengandung ujaran kebencian), sedangkan kelas 2 menjadi label 0 (tidak mengandung kebencian).

2.2 Preprocessing

Proses preprocessing dilakukan dengan tahapan: case folding, penghapusan tanda baca dan angka, tokenisasi, dan stopword removal menggunakan stopwords Bahasa Indonesia.

2.3 Representasi Fitur

Teks direpresentasikan menggunakan metode TF-IDF (Term Frequency - Inverse Document Frequency) untuk mengubah teks menjadi nilai numerik yang dapat diproses oleh algoritma machine learning.


2.4 Model Klasifikasi

Model yang digunakan pada penelitian ini adalah Naive Bayes Multinomial, yang umum digunakan untuk pemrosesan teks dan memiliki performa yang baik secara komputasi.

3. Hasil dan Analisis

Model diuji menggunakan 20% data uji. Hasil evaluasi menunjukkan bahwa model memiliki tingkat akurasi sekitar 84.56%. Model mampu mengenali ujaran kebencian dengan baik, namun performanya berkurang dalam mengenali teks yang tidak mengandung kebencian karena ketidakseimbangan data.

Distribusi Label Dataset:



Output Classification Report:

```
Accuracy: 0.8450675811983054
```

Classification Report:				
	precision	recall	f1-score	support
0	0.94	0.09	0.16	835
1	0.84	1.00	0.91	4122
accuracy			0.85	4957
macro avg	0.89	0.54	0.54	4957
weighted avg	0.86	0.85	0.79	4957

Tabel Confusion Matrix:

```
Confusion Matrix:
[[ 72 763]
 [  5 4117]]
```

```
[[ 72 763 ]
 [  5 4117 ]]
```

Berdasarkan confusion matrix tersebut, model cenderung mengklasifikasikan tweet sebagai ujaran kebencian. Hal ini disebabkan oleh banyaknya jumlah data dengan label ujaran kebencian dalam dataset.

4. Kesimpulan

Berdasarkan hasil penelitian, model mampu mendeteksi ujaran kebencian dengan akurasi yang cukup baik. Namun, diperlukan penyeimbangan data agar model juga dapat mengenali teks yang tidak mengandung kebencian secara lebih akurat. Pengembangan lebih lanjut dapat dilakukan dengan menggunakan model berbasis neural network seperti LSTM atau Transformer.